

ÉTUDE DE CAS — SPOTIFY

Stratégie de gouvernance des données

Livrable 1

Rapport de diagnostic de maturité des données

Certification — RNCP 38777 — Ahmed Mehdi SEMAR

Bloc 1 : Concevoir et piloter la politique de gouvernance des données de l'organisation.

1. Objet et périmètre du diagnostic

Ce rapport constitue la première étape de la stratégie de gouvernance des données de Spotify. Il établit un état des lieux objectif du niveau de maîtrise des données de l'entreprise, dimension par dimension, afin d'identifier les forces sur lesquelles s'appuyer et les écarts à combler en priorité.

Le diagnostic couvre l'ensemble du cycle de vie de la donnée chez Spotify : données d'usage et comportementales des utilisateurs, métadonnées de contenu (titres, podcasts), données démographiques, données d'abonnement et de facturation, et indicateurs d'engagement marketing. Il porte sur tous les départements (marketing, produit, ingénierie, contenu), toutes les régions d'opération et l'ensemble des systèmes de stockage (data lakes, bases relationnelles, cloud).

Ses conclusions alimentent directement les livrables suivants : la politique de gouvernance (Livrable 2) et le plan de mise en œuvre (Livrable 3).

2. Contexte : Spotify en 2023

Fondée en 2006 à Stockholm, Spotify est aujourd'hui l'un des leaders mondiaux du streaming audio. Son modèle, freemium et data-driven, repose sur une connaissance fine de l'utilisateur pour convertir l'audience gratuite vers l'abonnement Premium et alimenter son moteur de recommandation, principal facteur de différenciation face à Apple Music, Amazon Music ou Tidal.

Quelques ordres de grandeur structurants pour le diagnostic : **plus de 450 millions d'utilisateurs actifs** dont environ 200 millions d'abonnés Premium, une présence dans **plus de 180 pays** aux exigences réglementaires et culturelles hétérogènes, et des volumes de données générés et traités en temps réel.

Cette croissance rapide a dépassé la capacité d'adaptation du modèle de gouvernance d'origine. Quatre tensions ressortent du dossier d'entreprise et conditionnent l'évaluation qui suit :

- **Silos et fragmentation.** Chaque département gère ses propres jeux de données, ce qui empêche une vision unifiée de l'utilisateur et complique les analyses transverses (du parcours de découverte à la conversion).
- **Conformité multi-juridiction.** Spotify doit composer avec un patchwork réglementaire (RGPD, CCPA, PCI-DSS, et au-delà), avec des sanctions pouvant atteindre 20 M€ ou 4 % du chiffre d'affaires mondial annuel sous le RGPD.
- **Qualité des données.** Les imprécisions (préférences erronées, métadonnées obsolètes, doublons inter-systèmes) dégradent les recommandations et faussent le pilotage.
- **Confidentialité et accessibilité.** L'exigence croissante des utilisateurs et des régulateurs sur la vie privée doit être conciliée avec un accès fluide à des données de qualité pour les équipes internes.

3. Méthodologie d'évaluation

L'évaluation s'appuie sur les domaines de connaissance du Data Management Body of Knowledge (DMBOK) et note chaque dimension sur une échelle de maturité de 1 à 5, alignée sur les paliers usuels d'un modèle de type Gartner :

Niveau	Caractérisation
1 — Aware	Conscience du sujet, pratiques absentes ou informelles.
2 — Réactive	Actions ponctuelles, déclenchées par les incidents ou les obligations.
3 — Proactive	Processus définis et documentés, déploiement encore partiel et non homogène.
4 — Managed	Pratiques pilotées par des indicateurs, gouvernance outillée et mesurée.
5 — Effective	Gouvernance optimisée, amélioration continue ancrée dans la culture.

Chaque dimension est documentée par ses forces, ses faiblesses et une action prioritaire. Les sources mobilisées sont le dossier d'entreprise (business case) et l'analyse des pratiques observées.

4. Évaluation de la maturité par dimension

La grille ci-dessous synthétise la notation. Le détail argumenté suit le tableau.

Dimension DMBOK	Niveau (1–5)
Gouvernance des données	3,5
Architecture des données	4,0
Qualité des données	3,0
Conformité & protection	3,5
Usage & accessibilité	3,0
Sécurité des données	3,0
Culture data (literacy)	3,0
Gestion des métadonnées	2,5
Intégration des données	2,5
Analyse & décisionnel (BI)	4,5
Score global indicatif	≈ 3,2 / 5

Gouvernance des données — niveau 3,5/5

Forces. Une gouvernance existe déjà : présence d'un Chief Data Officer (CDO) et d'un Data Protection Officer (DPO), en lien avec le marketing, le juridique et les chefs de produit. Des rôles stratégiques sont identifiés.

Faiblesses. Les services se sont développés indépendamment au gré de la croissance ; pas de politique de gouvernance formalisée ni de référentiel commun. Les « cas particuliers » ne suivent pas les mêmes règles partout.

► **Action prioritaire.** Déployer, lors d'instances transverses animées par le CDO, des indicateurs partagés permettant une vision unifiée de l'usage des données.

Architecture des données — niveau 4,0/5

Forces. Architecture robuste, capable d'absorber des volumes massifs en continu : combinaison de data lakes, bases relationnelles et stockage cloud, avec traitements adaptés par pays.

Faiblesses. Sophistication qui se paie en complexité : adaptation aux évolutions techniques plus lourdes ; traçabilité et monitoring des flux insuffisants ; identifiants discontinus d'un système à l'autre.

► **Action prioritaire.** Identifier des porteurs (owners) par source de données, qui exposent et documentent des sources standardisées tout en restant personnalisables.

Qualité des données — niveau 3,0/5

Forces. La donnée est au cœur du métier : politique data-driven et moyens d'absorption en continu via des algorithmes ; les données alimentent l'ensemble des décisions.

Faiblesses. Caractère critique de la qualité (cf. business case) : complétude limitée, exactitude insuffisante, doublons et incohérences inter-sources, définitions divergentes (ex. « MAU » différent selon les zones), absence de tests systématiques.

► **Action prioritaire.** Définir des règles de cohérence partagées et des SLO de qualité par jeu de données, avec garants identifiés et procédures de nettoyage/normalisation.

Conformité & protection des données — niveau 3,5/5

Forces. Le RGPD est appliqué par défaut à tous les utilisateurs du fait de la domiciliation suédoise ; les enjeux réglementaires sont connus et des rôles dédiés existent.

Faiblesses. Couverture incomplète au regard de la diversité des 180 pays : un même utilisateur peut relever de plusieurs textes ; consentements non synchronisés, exercice des droits (DSR) inégal, effacement automatique absent, encadrement des transferts perfectible. Spotify a déjà été sanctionné au titre du RGPD.

► **Action prioritaire.** Automatiser l'application des règles selon la juridiction et industrialiser la gestion du consentement et des demandes d'exercice de droits.

Usage & accessibilité — niveau 3,0/5

Forces. L'accès aux données est encouragé et la culture d'usage existe ; les données servent réellement la prise de décision et la personnalisation.

Faiblesses. Le partage de données enrichies entre services reste lent et complexe (workflows « à la main », files d'attente, peu de self-service), créant des goulots d'étranglement.

► **Action prioritaire.** Mettre en place un portail unifié d'accès self-service avec gestion de profils et d'habilitations selon la criticité.

Sécurité des données — niveau 3,0/5

Forces. Le recours au cloud permet de déléguer une partie de la sécurité ; une base qualitative existe dans chaque périmètre.

Faiblesses. Recours nécessaire à de nombreux tiers (exposition accrue) ; contrôles fins non généralisés ; l'accès aux données reste le risque principal. Une amende RGPD a déjà sanctionné des manquements.

► **Action prioritaire.** Renforcer la gestion des accès (RBAC/ABAC, moindre privilège), le chiffrement des données sensibles et la journalisation, avec tests réguliers.

Culture data (literacy) — niveau 3,0/5

Forces. Spotify encourage déjà l'usage de la donnée à tous les niveaux et communique sur son importance ; accès facilité pour les collaborateurs.

Faiblesses. Pas de dispositif garantissant que l'information se transforme en connaissance ; bases hétérogènes sur les KPI, les bases légales, la privacy et la qualité. Le besoin de formations exprimé indique leur quasi-absence.

► **Action prioritaire.** Déployer un dispositif de formation continu et inclusif, valoriser les réalisations data pour ancrer la confiance.

Gestion des métadonnées — niveau 2,5/5

Forces. Une connaissance métier des données existe au sein de chaque équipe.

Faiblesses. Catalogue et glossaire incomplets, lineage des flux critiques manquant, classification/marquage des données personnelles (PII) insuffisant.

► **Action prioritaire.** Déployer un catalogue de données avec glossaire, lineage des flux critiques et étiquetage systématique des PII.

Intégration des données — niveau 2,5/5

Forces. Des sources de qualité existent localement et l'architecture sait ingérer de multiples flux.

Faiblesses. Silos persistants, identifiants différents selon les systèmes, pipelines en doublon, peu de CDC et de référentiel commun (MDM) : pas de vision 360° fiable de l'utilisateur.

► **Action prioritaire.** Déployer un MDM (identifiants communs / golden record) et un socle d'intégration commun proposant les mêmes sources à toutes les entités.

Analyse & décisionnel (BI) — niveau 4,5/5

Forces. Cœur de l'activité : moteur de recommandation reconnu, décisions stratégiques massivement appuyées sur la donnée. C'est le point fort distinctif de Spotify.

Faiblesses. Métriques parfois divergentes et prolifération de tableaux non certifiés ; la qualité en amont reste le principal facteur limitant.

► **Action prioritaire.** Certifier les dashboards et la couche sémantique (mêmes définitions pour tous) ; préserver l'explicabilité des modèles.

5. Score global et positionnement

La moyenne des dimensions évaluées situe Spotify à un niveau de maturité global d'environ **3,2 sur 5**, soit une position à la charnière entre les paliers **Réactive** et **Proactive**.

Le profil est nettement contrasté. Spotify excelle là où la donnée crée directement de la valeur produit — analyse et décisionnel (4,5) et architecture (4,0) — ce qui témoigne d'une entreprise authentiquement data-driven. À l'inverse, les fondations transverses de la gouvernance restent en retrait : l'intégration (2,5) et la gestion des métadonnées (2,5) sont les maillons faibles, conséquence directe des silos hérités d'une croissance rapide.

Autrement dit, Spotify sait exploiter ses données mieux qu'elle ne les gouverne. Le diagnostic ne révèle pas une organisation immature, mais une organisation performante dont le cadre de gouvernance n'a pas suivi le rythme de l'expansion. L'enjeu n'est donc pas de tout reconstruire, mais de fédérer et d'industrialiser l'existant.

6. Synthèse : enjeux et axes stratégiques

Cinq axes prioritaires se dégagent du diagnostic. Ils structureront la politique de gouvernance (Livrable 2) et son plan de mise en œuvre (Livrable 3) :

- **A1 — Consolider la conformité réglementaire multi-juridiction.** Au-delà du RGPD, du CCPA et du PCI-DSS, anticiper la mosaïque internationale (PDPA, LGPD, etc.) et automatiser l'application des règles par zone.
- **A2 — Industrialiser la qualité des données.** SLO par jeu de données, référentiel et MDM, catalogue, glossaire et lineage pour fiabiliser la matière première du moteur de recommandation.
- **A3 — Casser les silos par le modèle organisationnel.** Faire évoluer la gouvernance intégrée actuelle vers un Centre d'Excellence (CoE) fédéré, conciliant standards centraux et autonomie des domaines.
- **A4 — Acculturer et former l'ensemble des collaborateurs.** Dispositif de formation continu, inclusif et accessible, pour transformer l'accès à la donnée en compétence partagée.
- **A5 — Renforcer la sécurité et la traçabilité.** Gestion fine des accès, chiffrement des données sensibles, journalisation et audits réguliers, locaux comme internationaux.

En conclusion, Spotify dispose des atouts d'une entreprise mûre (architecture, analytics, culture d'usage) mais d'une gouvernance encore réactive. Le passage au palier « Managed » suppose de fédérer les pratiques, d'industrialiser la qualité et la conformité, et d'ancrer une culture data partagée — objet des livrables suivants.